# Нейросетевые методы поиска и сегментации объектов в данных современных космических обзоров

Научные руководители:
Герасимов С.В., к.ф.-м.н. Мещеряков А.В.
Студент: Немешаева Алиса,
4 курс бакалавриата ВМК МГУ

# Введение: eRosita

- Рентгеновский телескоп eROSITA снимет всё небо и составит восемь карт неба в мягком рентгеновском излучении.
- Ожидается, что рентгеновский телескоп eROSITA обнаружит 100 000 скоплений галактик.
- Основная научная цель состоит в том, чтобы измерить темную энергию через структуру и историю развития Вселенной, отслеживаемую скоплениями галактик.

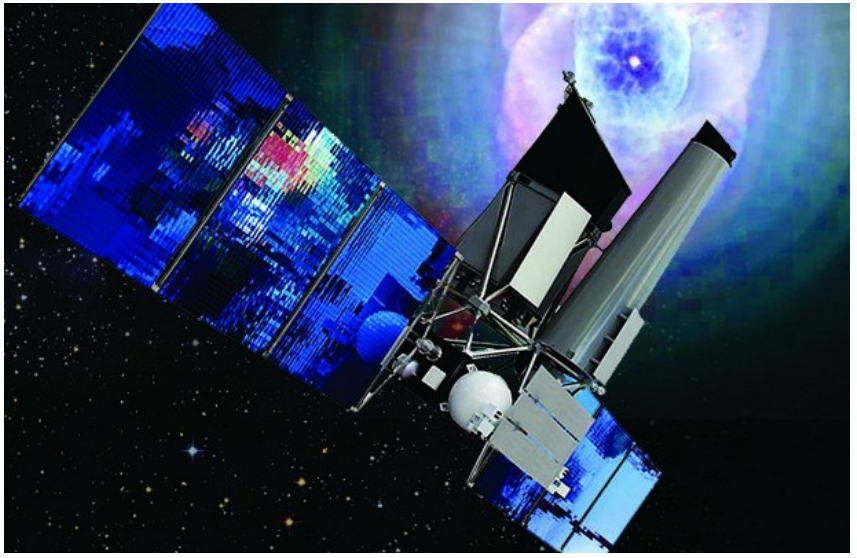

# Введение: скопления галактик

- Скопления - это самые большие гравитационно связанные структуры во Вселенной. Скопления галактик играют важную роль в задачах определения параметров Вселенной. Скопления галактик излучают энергию в разных диапазонах, и существует множество классических методов для поиска скоплений в различных данных.
- Скопления являются базовыми “кирпичиками”, из которых строится Вселенная. Изучая их параметры, можно исследовать структуру локальной Вселенной.

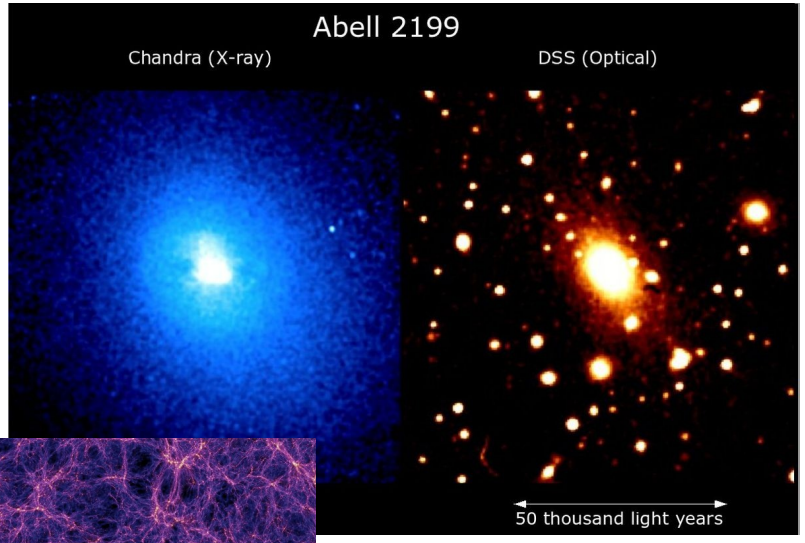


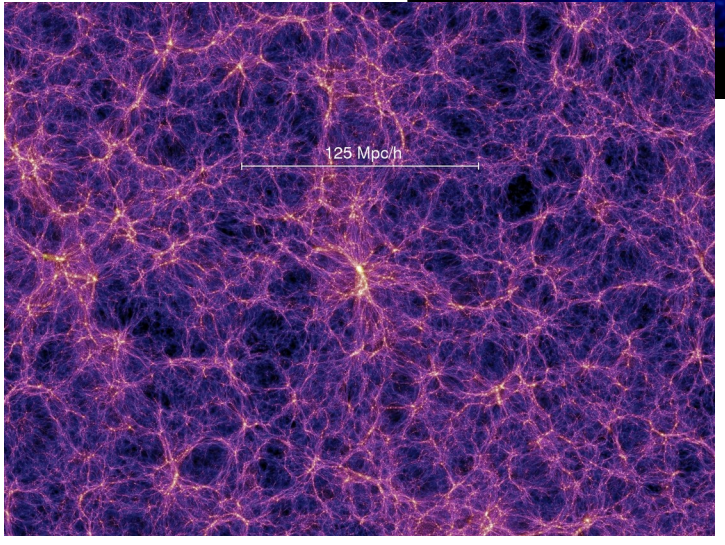

# Введение: Planck

Для начала будут использоваться данные микроволнового телескопа Planck в 6 каналах.

Данные этого телескопа покрывают всё небо.

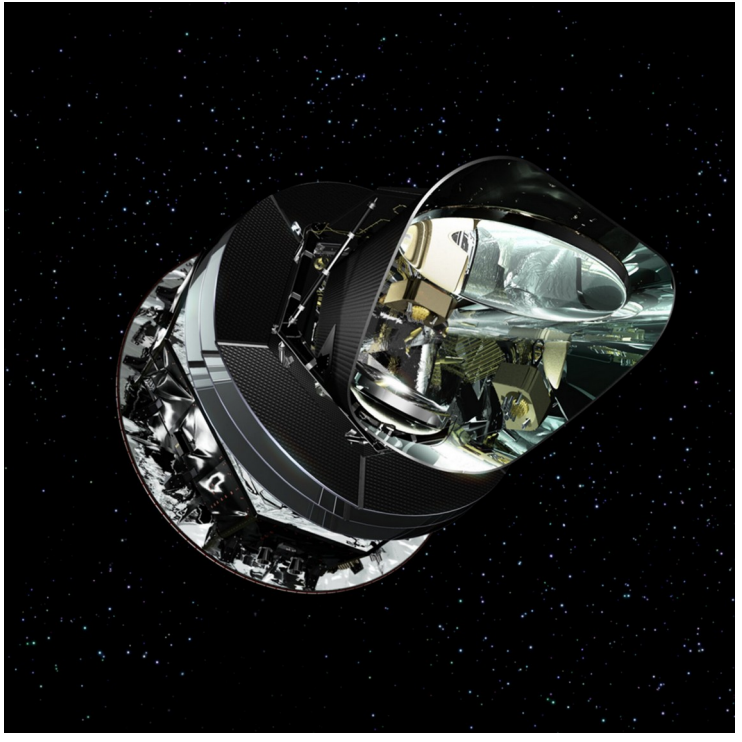

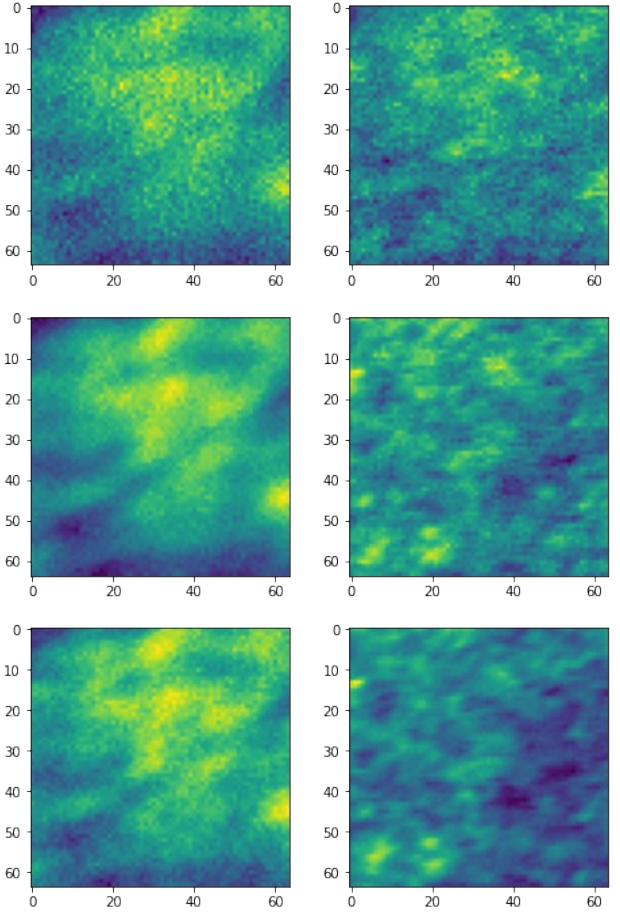

# Введение

Эффект Сюняева-Зельдовича — изменение интенсивности радиоизлучения реликтового фона на горячих электронах межзвёздного и межгалактического газа.

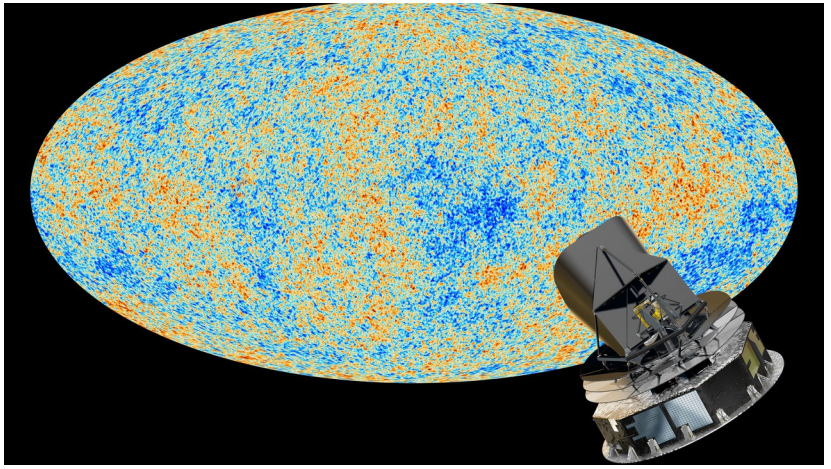

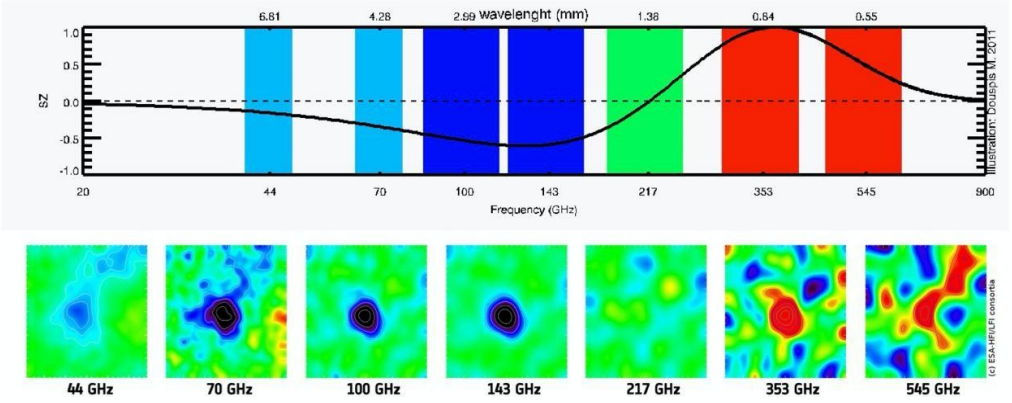


**Fig. 2.** Abell 2319 seen by *Planck* between 44 GHz and 545 GHz.

# Введение

Создание каталогов данных в других диапазонах может помочь уточнить данные каталогов для других диапазонов.

Исследователям важно знать не только координаты скоплений, но и их параметры – красное смещение и массу.

Кроме того, важно иметь возможность составлять либо максимально точные, либо максимально полные каталоги скоплений. Возникает задача ранжирования детектированных объектов.

Поэтому кроме детекции появляется и задача классификации детектированных объектов.

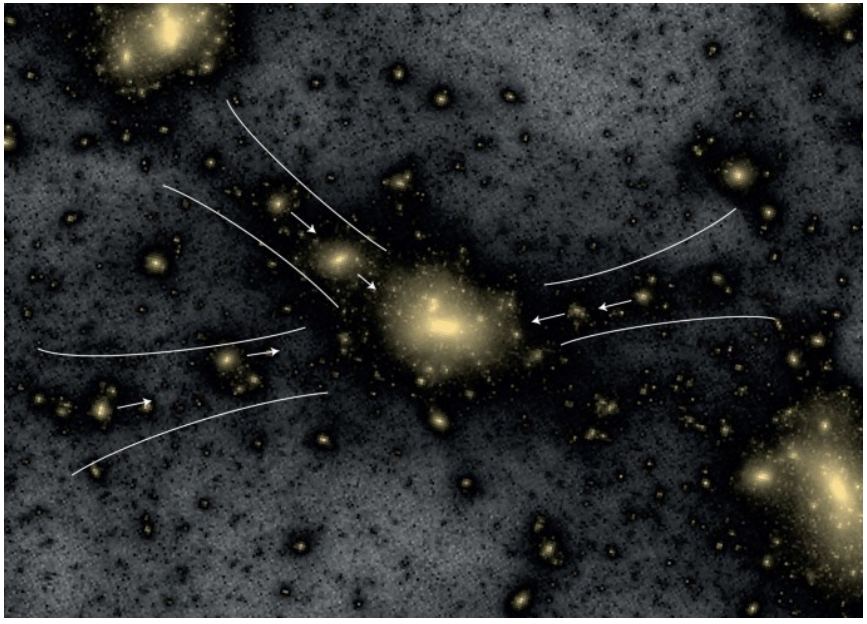

# Актуальность: преимущества глубокого обучения

- Стандартные алгоритмы сегментации усредняют информацию по нескольким каналам, в то время как с помощью нейросети можно охватить данные полностью.
- Каждый из классических методов имеет свои достоинства и недостатки, и для каждого диапазона излучения существуют свои алгоритмы, в то время как нейросеть может стать универсальным средством для сегментации данных нескольких каналов одновременно.
- Нейронные сети позволяют извлекать признаки прямо из данных.

# Постановка задачи

- Исследование и разработка нейросетевых методов сегментации, детекции и классификации скоплений галактик в многоволновых данных обзоров неба, а также построение каталогов скоплений.

# Структура работы

- Обзор данных и обзор методов
- Построение решения
  - Предварительная обработка данных
  - Обучение модели
  - Создание каталога скоплений
- Результаты

# Обзор данных и обзор методов

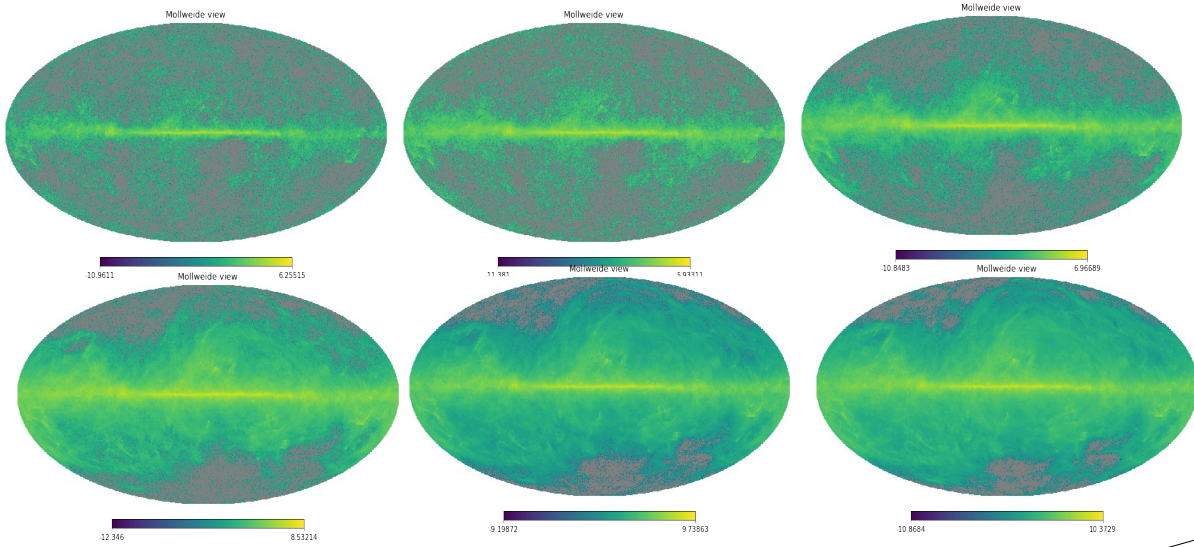


Карты Planck

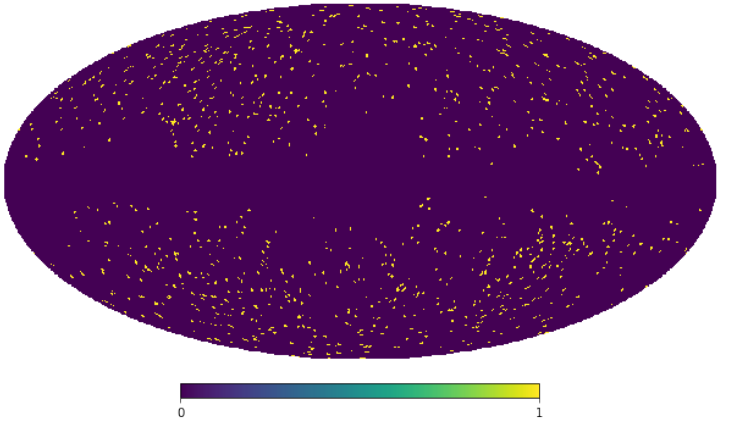


Тренировочный каталог

Модель
+
алгоритм
детекции

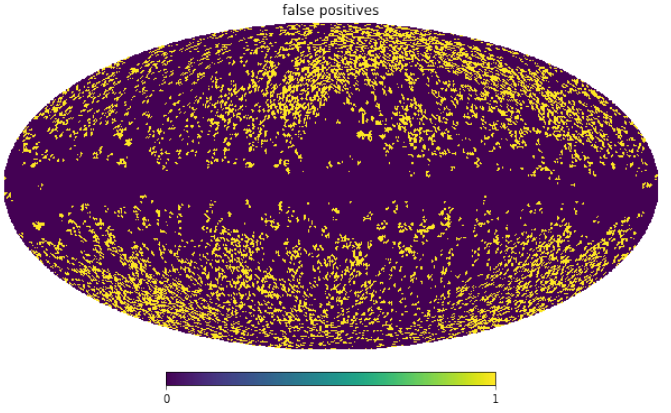


Новый каталог

# Существующие каталоги

- Рентгеновские:
  - eRosita
  - MCXC
- Микроволновые:
  - PSZ2
  - ACT
- Оптические:
  - RedMaPPer

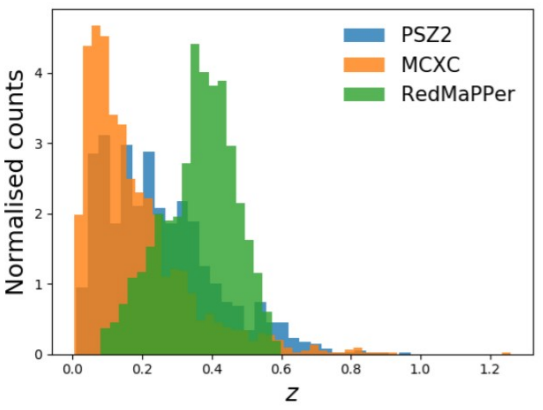


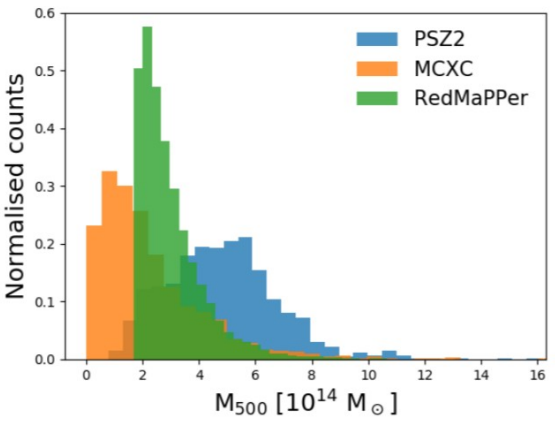

# Обзор: “Детекция эффекта Сюняева-Зельдовича”

https://www.aanda.org/articles/aa/pdf/2020/02/aa36919-19.pdf

Автор этой статьи использует для сегментации данных архитектуру U-net. Основной целью описываемой работы являлось создание алгоритма для детекции источников через эффект Сюняева-Зельдовича по данным телескопа Planck. Кроме самих обзоров неба, полученных телескопом, использовались еще три каталога скоплений для создания целевых данных:

- PSZ2 → planck_z, planck_no_z
- MCXC → mcxcwp
- RedMaPPer → rm30, rm50

В открытом доступе не существует каталогов, полученных автором этой статьи, поэтому полезно повторить эксперимент, чтобы получить самостоятельно эти каталоги, а также сравнить результаты с новым микроволновым каталогом ACT, которого на момент написания этой статьи ещё не было.

# Обзор: U-net

U-net является стандартной архитектурой для сегментации данных. Она подходит для проверки идеи использования методов глубокого обучения для сегментации скоплений. Её симметричная структура позволяет абстрагировать данные изображения, подаваемого на вход, в то время как skip-connection слои помогают увеличивать точность сегментации.

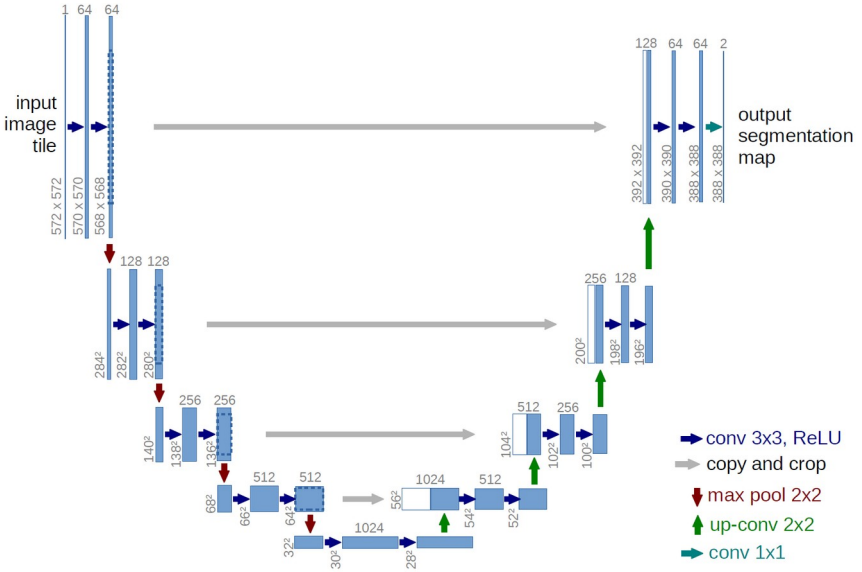

# Построение решения

1) Предобработка.

2) Генерация данных для обучения.

3) Обучение модели, подбор параметров модели.

4) Применение модели, детекция.

5) Создание каталога скоплений, его анализ.

# Предобработка данных

# Предобработка данных

- Данные Planck в разных каналах сильно отличаются по диапазонам значений. Чтобы улучшить результаты обучения, их нужно нормализовать, но так, чтобы можно было выделить значения, сильно отличающиеся от остальных.

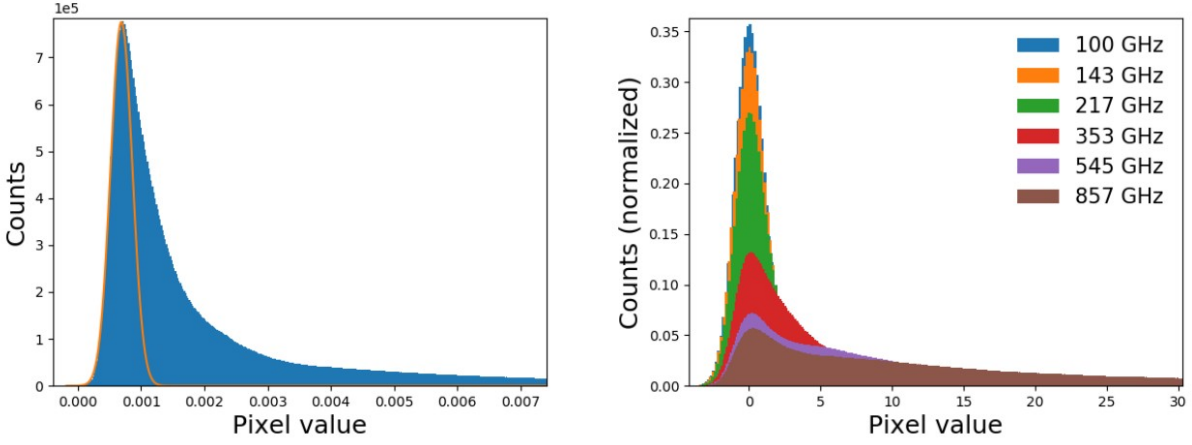


**Fig. 2.** Illustration of the data pre-processing. *Left*: pixel distribution of the map at 353 GHz. A Gaussian is fitted in orange up to the statistical mode of the distribution. The mean and standard deviation of the fitted Gaussian are used to normalise the data. *Right*: pixel distribution after normalisation of the six *Planck* HFI frequency maps.

# HEALPix

- HEALPix – алгоритм иерархического разбиения сферы.
- Позволяет спроектировать на сферу данные и выбрать для них подходящее разрешение.
- Данные Planck хранятся в качестве изображения сферы, проиндексированного согласно HEALPix.
- HEALPix не искажает площадь объекта, но может искажать форму.

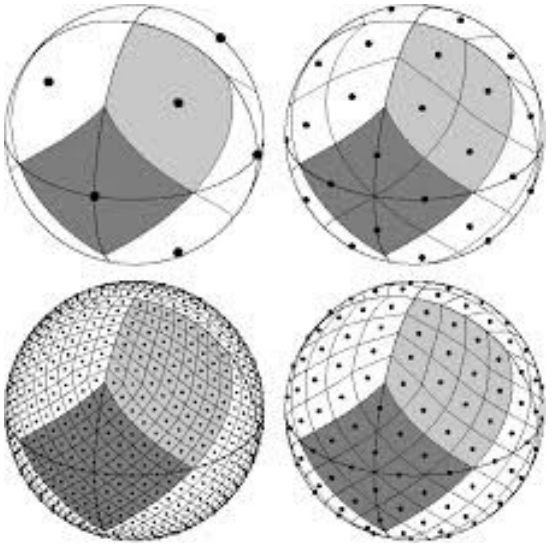

# Проекция данных

- Данные Planck хранятся в разбиении HEALPix, в нем же происходили обучение модели и детекция объектов.
- Разбиение с параметром $n_{side}=2$ позволяет получить 48 больших областей неба. Некоторые из них были использованы для тестирования полученной модели и для валидации, все остальные были использованы для обучения модели.

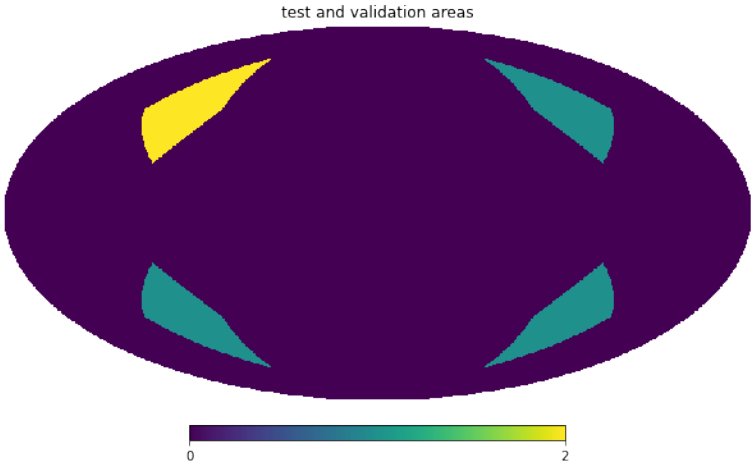

# Генерация патчей для обучения

Случайным образом в соответствующих областях разбиения выбирались центры патчей и их ориентации для создания тренировочных и тестовых выборок. Каждый патч представлял из себя изображение размера 64 x 64 с шестью каналами различных данных.

После этого 100000 патчей были использованы для обучения нейросети.

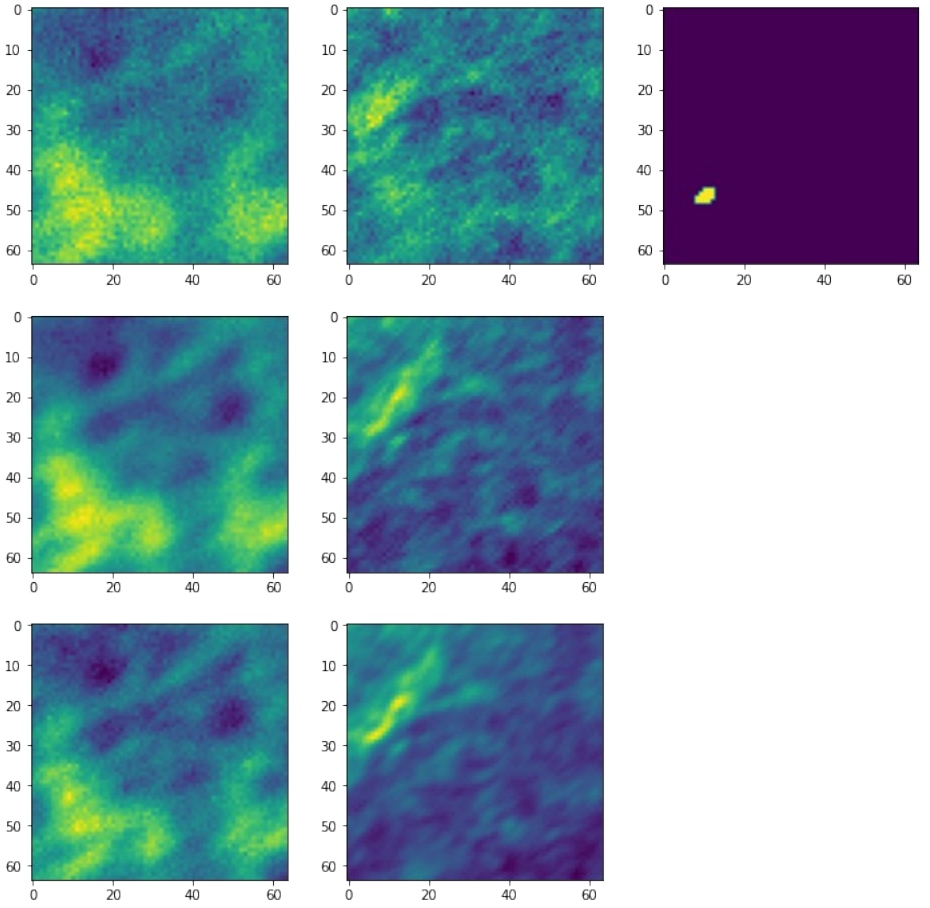

# Создание каталога

# Сканирование неба

- Чтобы полностью просканировать область неба, нужно разбить её на патчи размером 64x64, так же, как для обучения.
- Есть смысл сканировать некоторые данные повторно, так, чтобы разные части сканируемой области попадали в разные части патча.
- После сканирования полученные маски нужно объединить в общую predicion маску для всей сканируемой области неба.
- Таким образом появляется новый параметр детекции – “шаг”.

Step = 64 = size

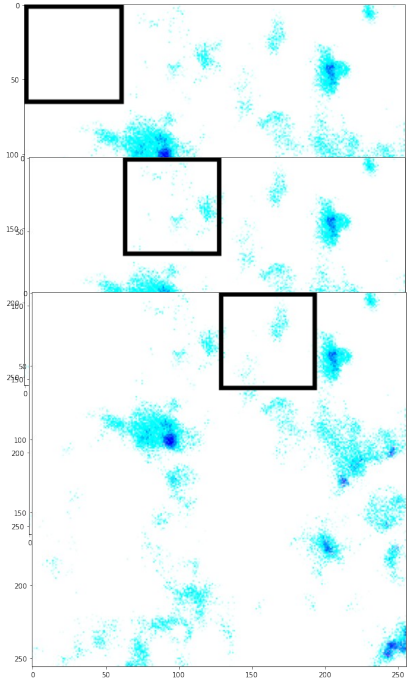

Step = 32 = size / 2

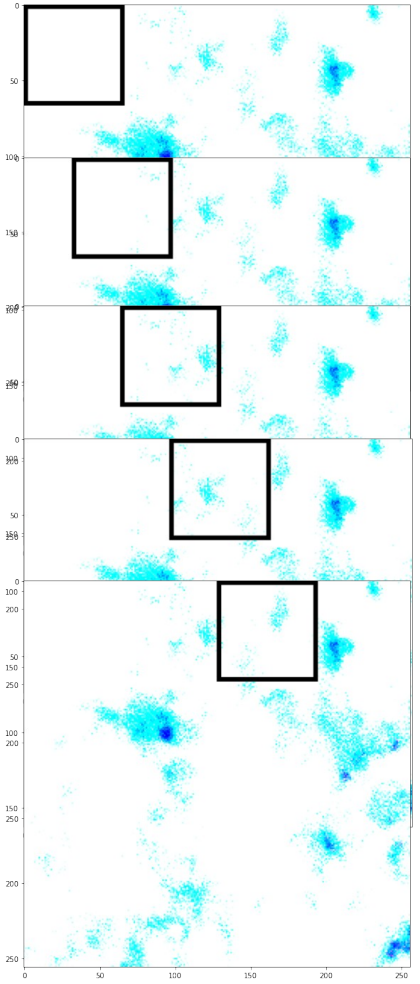

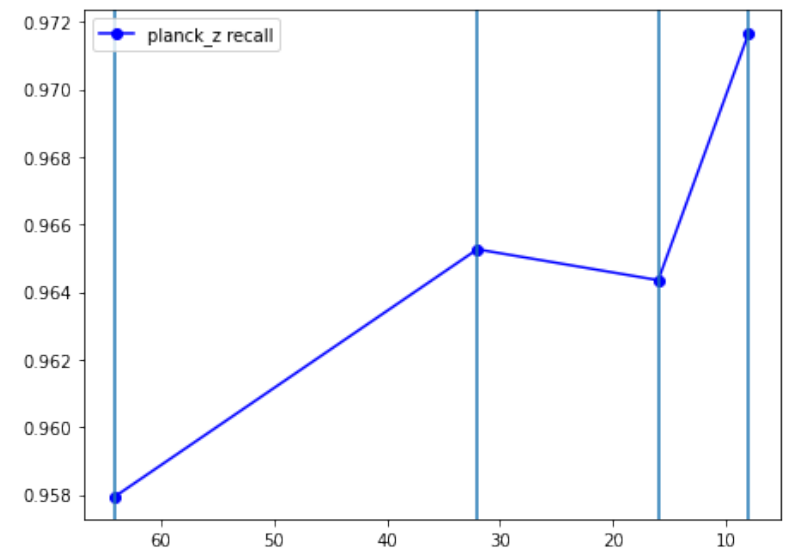


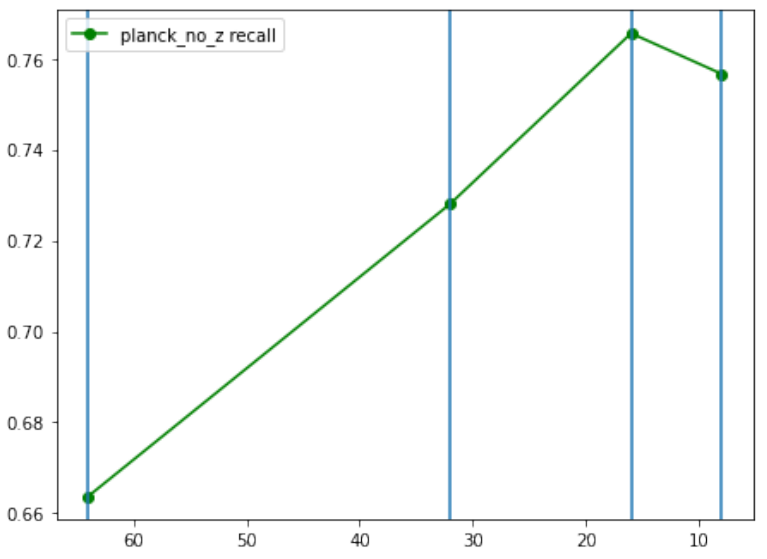


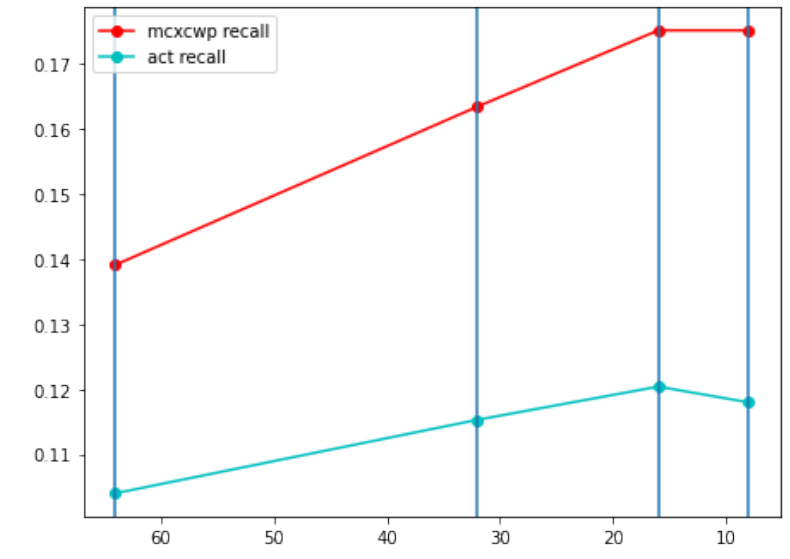


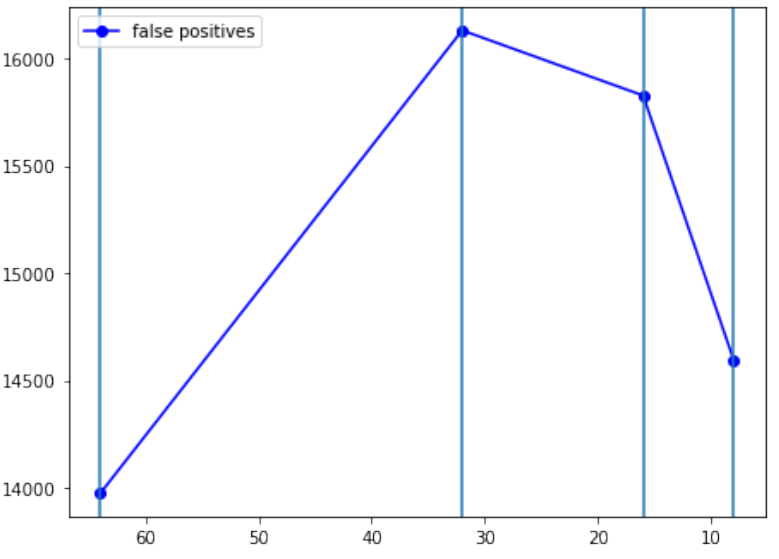


При уменьшении шага окна сканирования (step) мы наблюдаем увеличение полноты (recall) и уменьшение количества ложных объектов (fp) в ~1.132 раза.

# Создание каталога

- После получения маски сегментации для выбранной области неба выбирается порог детекции thr.
- На маске обнуляются пиксели, значение которых < thr.
- На маске “пятна” отделяются друг от друга.
- У каждого “пятна” находим барицентр.
- Координаты преобразовываем в Ra, Dec.

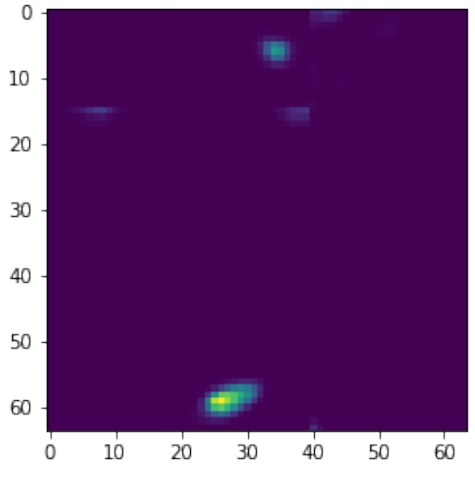


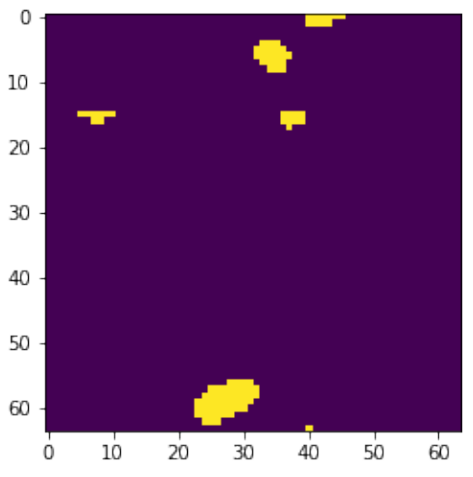


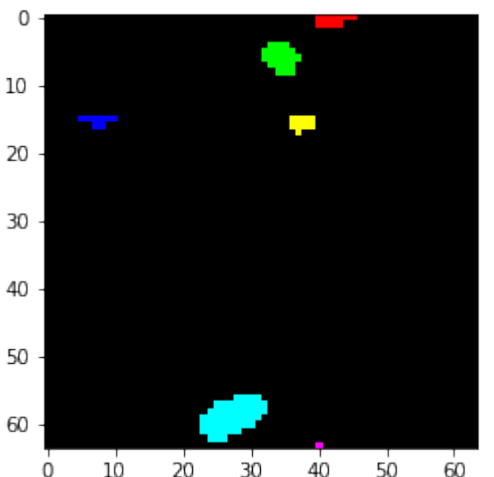

# Сопоставление результатов с существующими каталогами

- Чтобы оценить, насколько хорошо получилось детектировать объекты, нужно сравнить свои результаты с существующими каталогами скоплений, рассматривая разные параметры детекции и обучения.

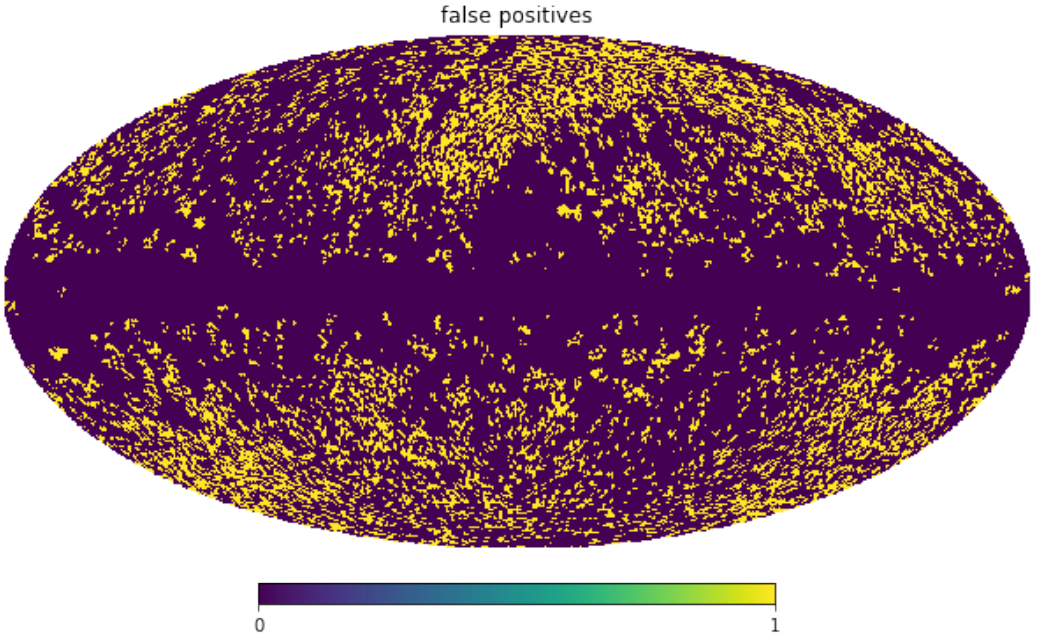

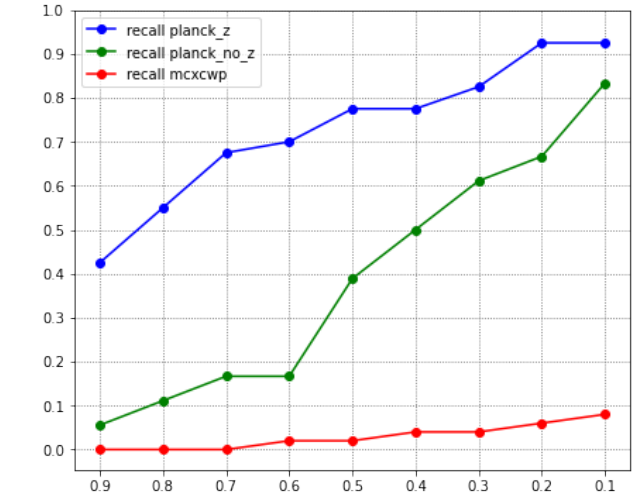


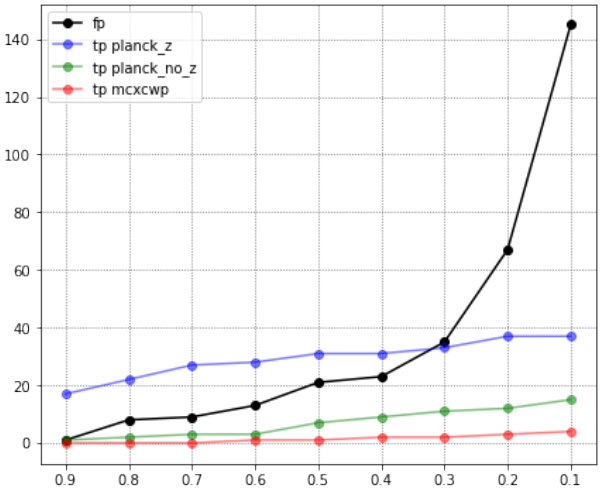


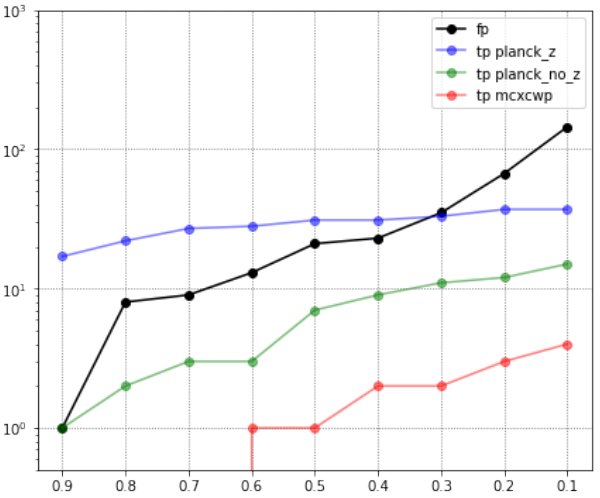


A&A 634, A81 (2020)

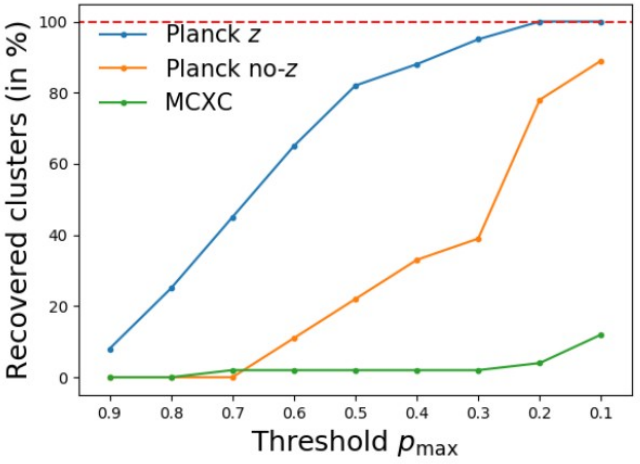


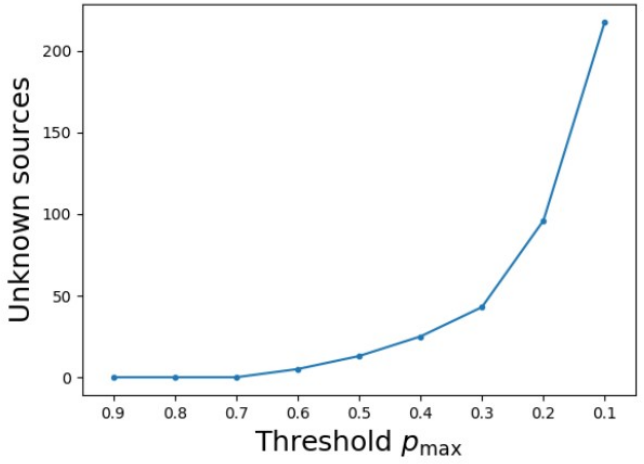


Количество неизвестных источников получилось на порядок ниже, отклик по planck_z ниже

**Fig. 3.** Results on the test area containing 40 `Planck_z`, 18 `Planck_no-z`, and 50 `MCXCwP` galaxy clusters. *Left*: Galaxy clusters recovered with different detection thresholds $p_{max}$. *Right*: number of sources recovered with the U-net that do not belong to the *Planck* or the MCXC catalogue as a function of the threshold $p_{max}$.

# Структура каталога

- Созданы каталоги с параметрами:
  - Area – площадь сегментированной области скопления
  - min_rad, max_rad, mean_rad – минимальный, максимальный, средний радиусы области
  - min_pred, max_pred – минимальное, максимальное значение маски в области
  - Status – факт сопоставления скопления с объектом из каталога

| RA | DEC | area | min_rad | max_rad | mean_rad | min_pred | max_pred | tRA | tDEC | status | catalog |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 259.732221 | 5.094132 | 4.0 | 0.701176 | 2.119449 | 1.320277 | 0.901549 | 0.933698 | NaN | NaN | fp | NaN |
| 283.542185 | 26.460609 | 4.0 | 0.700159 | 2.110640 | 1.317352 | 0.901048 | 0.957279 | 283.519410 | 26.482998 | tp | planck_no_z |
| 280.308927 | 30.912179 | 7.0 | 0.700308 | 2.503611 | 1.673052 | 0.900285 | 0.988940 | 280.278406 | 30.932247 | tp | planck_z |
| 276.363142 | 30.419430 | 7.0 | 0.292191 | 2.616653 | 1.576871 | 0.906883 | 0.985809 | 276.336046 | 30.431996 | tp | planck_z |
| 266.093042 | 32.971296 | 5.0 | 0.447466 | 2.275328 | 1.422385 | 0.903614 | 0.968407 | 266.067814 | 32.998643 | tp | planck_z |

# Результаты

# Сравнение с каталогом eRosita

- По данным eRosita также составляются каталоги, с которыми можно сравнивать полученные результаты.
- Эти каталоги созданы без использования нейросетевых методов.
- Ancat и psz2 созданы по одним и тем же данным, но в ancat найдено  640 других объектов в каталоге eRosita. Полученный каталог является наиболее полным каталогом кадидатов в скопления по данным Planck.
- Psz2 – каталог самых надежных объектов данных Planck.
- Brcat – более полный каталог на данных Planck созданный  стандартным методом.
- Redmp – каталог RedMaPPer.

Каталог с planck_z

Matrix of UNIQUE eRosita matches

| | ancat | brcat | psz2 | redmp |
|---|---|---|---|---|
| ancat | 1704 | 1064 | 574 | 676 |
| brcat | 1064 | 1715 | 531 | 641 |
| psz2 | 574 | 533 | 593 | 227 |
| redmp | 680 | 643 | 228 | 4461 |

Каталог с planck_z и act

Matrix of UNIQUE eRosita matches

| | ancat | brcat | psz2 | redmp |
|---|---|---|---|---|
| ancat | 2355 | 1022 | 590 | 993 |
| brcat | 1020 | 1715 | 531 | 641 |
| psz2 | 589 | 533 | 593 | 227 |
| redmp | 994 | 643 | 228 | 4461 |

# Текущие результаты

Созданы алгоритмы предобработки данных Planck.

- Обучена модель для сегментации данных Planck.
- Созданы алгоритмы детекции масок сегментации, производимых моделью.
- Созданы каталоги по моделям, обученным на каталогах planck_z и plank_z+act.

# Дальнейшие планы

- Классификация.
- Статья о полученных каталогах.
- Перейти на детекцию скоплений в других диапазонах излучения.

# Дальнейшие планы

- Готовы алгоритмы для предобработки оптических данных DESI LIS.
- Однако их разрешение выше, чем разрешение данных Planck, поэтому нужно придумать, как соединить эти каналы.

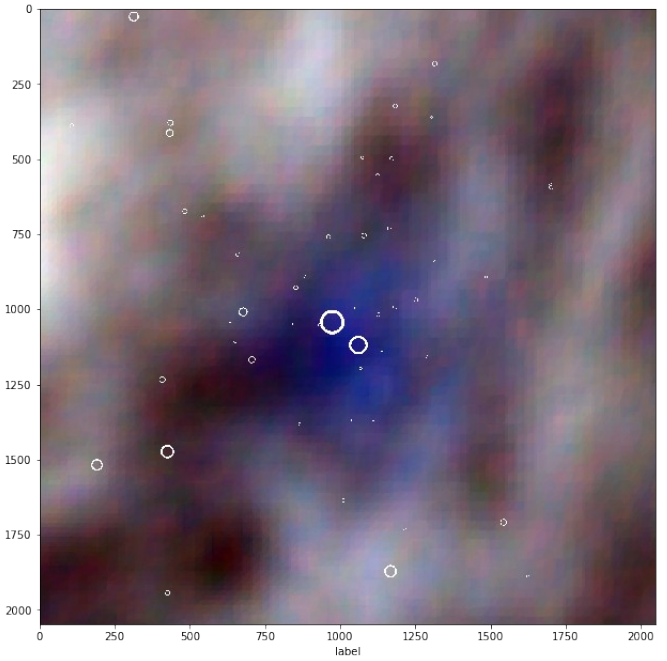

# Дальнейшие планы

Оптические данные

Микроволновые данные

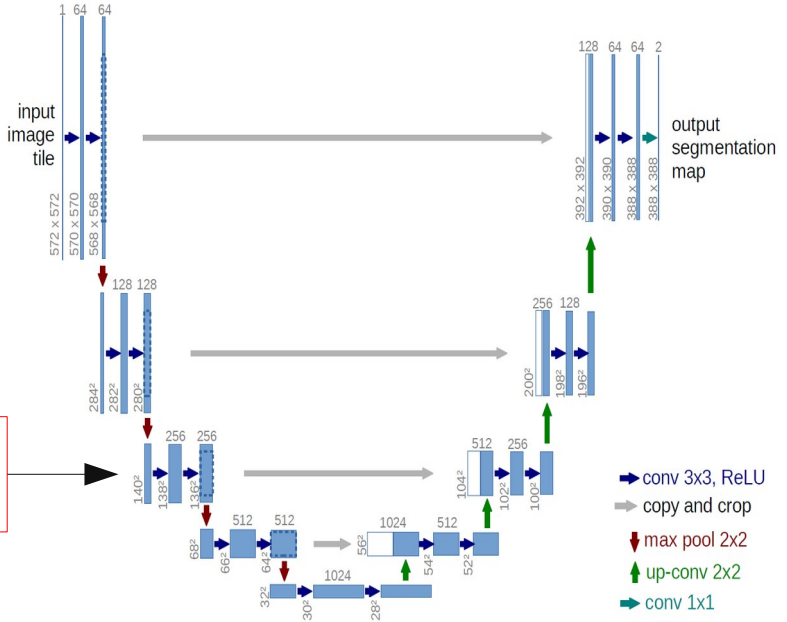


Один из вариантов: добавлять разные данные на разные блоки кодировщика U-net.

Спасибо за внимание