

Нейросетевые методы поиска и сегментации объектов в данных современных космических обзоров

Научные руководители:
Герасимов С.В., к.ф.-м.н. Мещеряков А.В.
Студент: Немешаева Алиса,
4 курс бакалавриата ВМК МГУ


Введение

- Скопления - это гравитационно связанные системы, которые являются самыми большими структурами во Вселенной. Скопления галактик играют важную роль в задачах определения параметров Вселенной. Скопления галактик излучают энергию в разных диапазонах, и их можно наблюдать не только в рентгеновских данных.

Введение

В данной работе будут использоваться данные микроволнового телескопа Planck в 6 каналах.

Данные этого телескопа покрывают всё небо.



Актуальность

Методы глубокого обучения дают следующие преимущества при анализе данных:

- Стандартные алгоритмы сегментации усредняют информацию по нескольким каналам, в то время как с помощью нейросети можно охватить данные полностью.
- Каждый из классических методов имеет свои достоинства и недостатки, и для каждого диапазона излучения существуют свои алгоритмы, в то время как нейросеть может стать универсальным средством для сегментации.

Постановка задачи

Исследование проблемы сегментации и детекции объектов в многоволновых диапазонах и разработка алгоритма для предобработки данных, а также создание нейросетевой модели, позволяющей выполнять сегментацию и детекцию скоплений галактик на данных различных диапазонов.

План решения задачи

1) Обзор существующих решений.

→ 2) Предобработка.

3) Генерация данных для обучения.

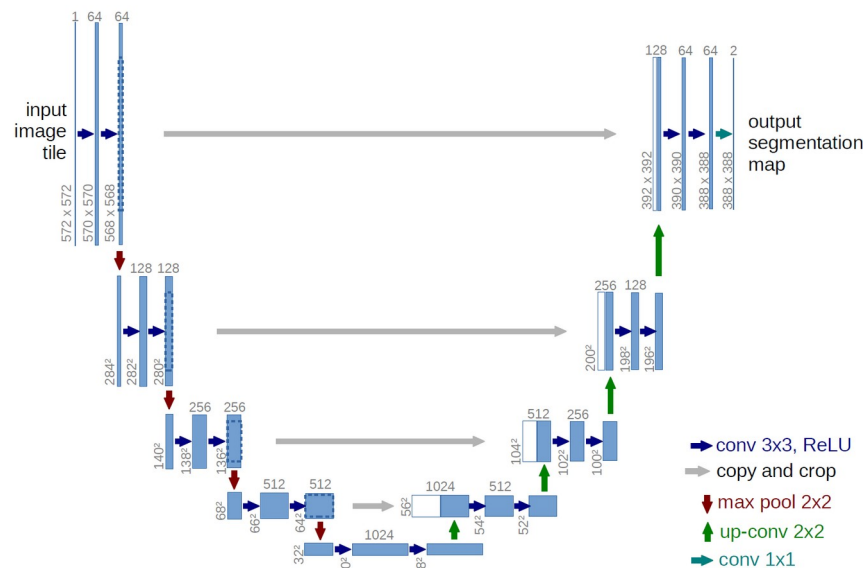
4) Создание модели.

5) Обучение модели, подбор параметров модели.

6) Детекция и подбор параметров детекции.

Обзор: U-net

U-net является стандартной архитектурой для сегментации данных. Она подходит для проверки идеи использования методов глубокого обучения для сегментации скоплений. Её симметричная структура позволяет абстрагировать данные изображения, подаваемого на вход, в то время как skip-connection слои помогают увеличивать точность сегментации.



Обзор: “Детекция эффекта Сюняева-Зельдовича”

<https://www.aanda.org/articles/aa/pdf/2020/02/aa36919-19.pdf>

Автор этой статьи использует для сегментации данных архитектуру U-net. Основной целью описываемой работы являлось создание алгоритма для детекции источников через эффект Сюняева-Зельдовича по данным телескопа Planck. Кроме самих обзоров неба, полученных телескопом, использовались еще три каталога скоплений для создания целевых данных:

- PSZ2
- MCXC
- RedMaPPer

Обработка данных

- Данные Planck в разных каналах сильно отличаются по диапазонам значений. Чтобы улучшить результаты обучения, их нужно нормализовать, но так, чтобы можно было выделить значения, сильно отличающиеся от остальных.

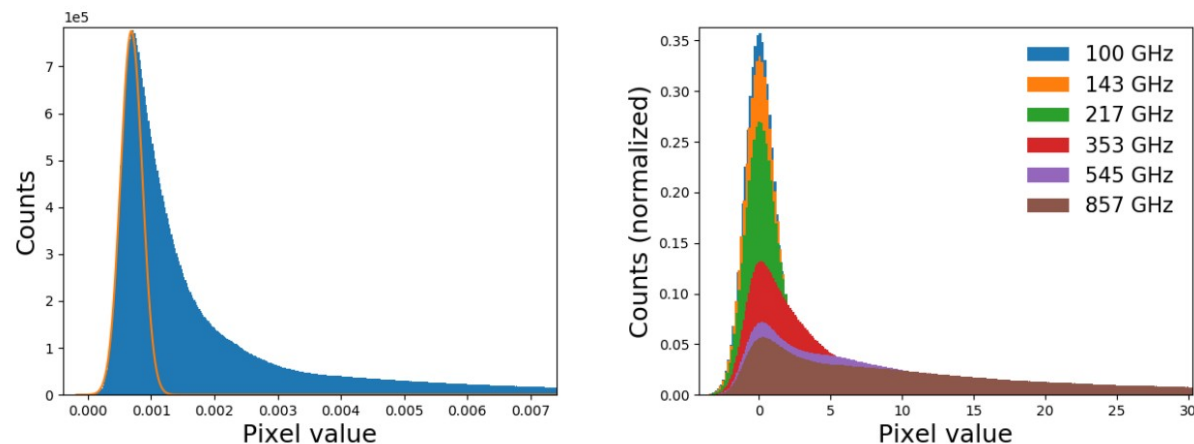



Fig. 2. Illustration of the data pre-processing. *Left:* pixel distribution of the map at 353 GHz. A Gaussian is fitted in orange up to the statistical mode of the distribution. The mean and standard deviation of the fitted Gaussian are used to normalise the data. *Right:* pixel distribution after normalisation of the six *Planck* HFI frequency maps.

Проекция данных


- Данные Planck хранятся в проекции HEALPix, в этой же проекции происходили обучение модели и детекция объектов.
- Разбиение с параметром $n_{\text{side}}=2$ позволяет получить 48 больших областей неба. Некоторые из них были использованы для тестирования полученной модели и для валидации, все остальные были использованы для обучения модели.



Генерация данных


Случайным образом в соответствующих областях разбиения выбирались центры патчей и их ориентации для создания тренировочных и тестовых выборок. Каждый патч представлял из себя изображение размера 64 x 64 с шестью каналами различных данных.

После этого 100000 патчей были использованы для обучения нейросети.






Детекция

- Чтобы полностью просканировать область неба, нужно разбить её на патчи размером 64x64, так же, как для обучения.
- Есть смысл сканировать некоторые данные повторно, так, чтобы разные части сканируемой области попадали в разные части патча.
- После сканирования полученные маски нужно объединить в общую prediction маску для всей сканируемой области неба.
- Таким образом появляется новый параметр детекции – “шаг”.



Детекция

- После получения маски сегментации для выбранной области неба выбирается порог детекции thr .
- На маске обнуляются пиксели, значение которых $< thr$.
- На маске “пятна” отделяются друг от друга.
- У каждого “пятна” находим барицентр.
- Координаты преобразовываем в Ra , Dec .



Сопоставление результатов с существующими каталогами

- Чтобы оценить, насколько хорошо получилось детектировать объекты, нужно сравнить свои результаты с существующими каталогами скоплений, рассматривая разные параметры детекции и обучения.

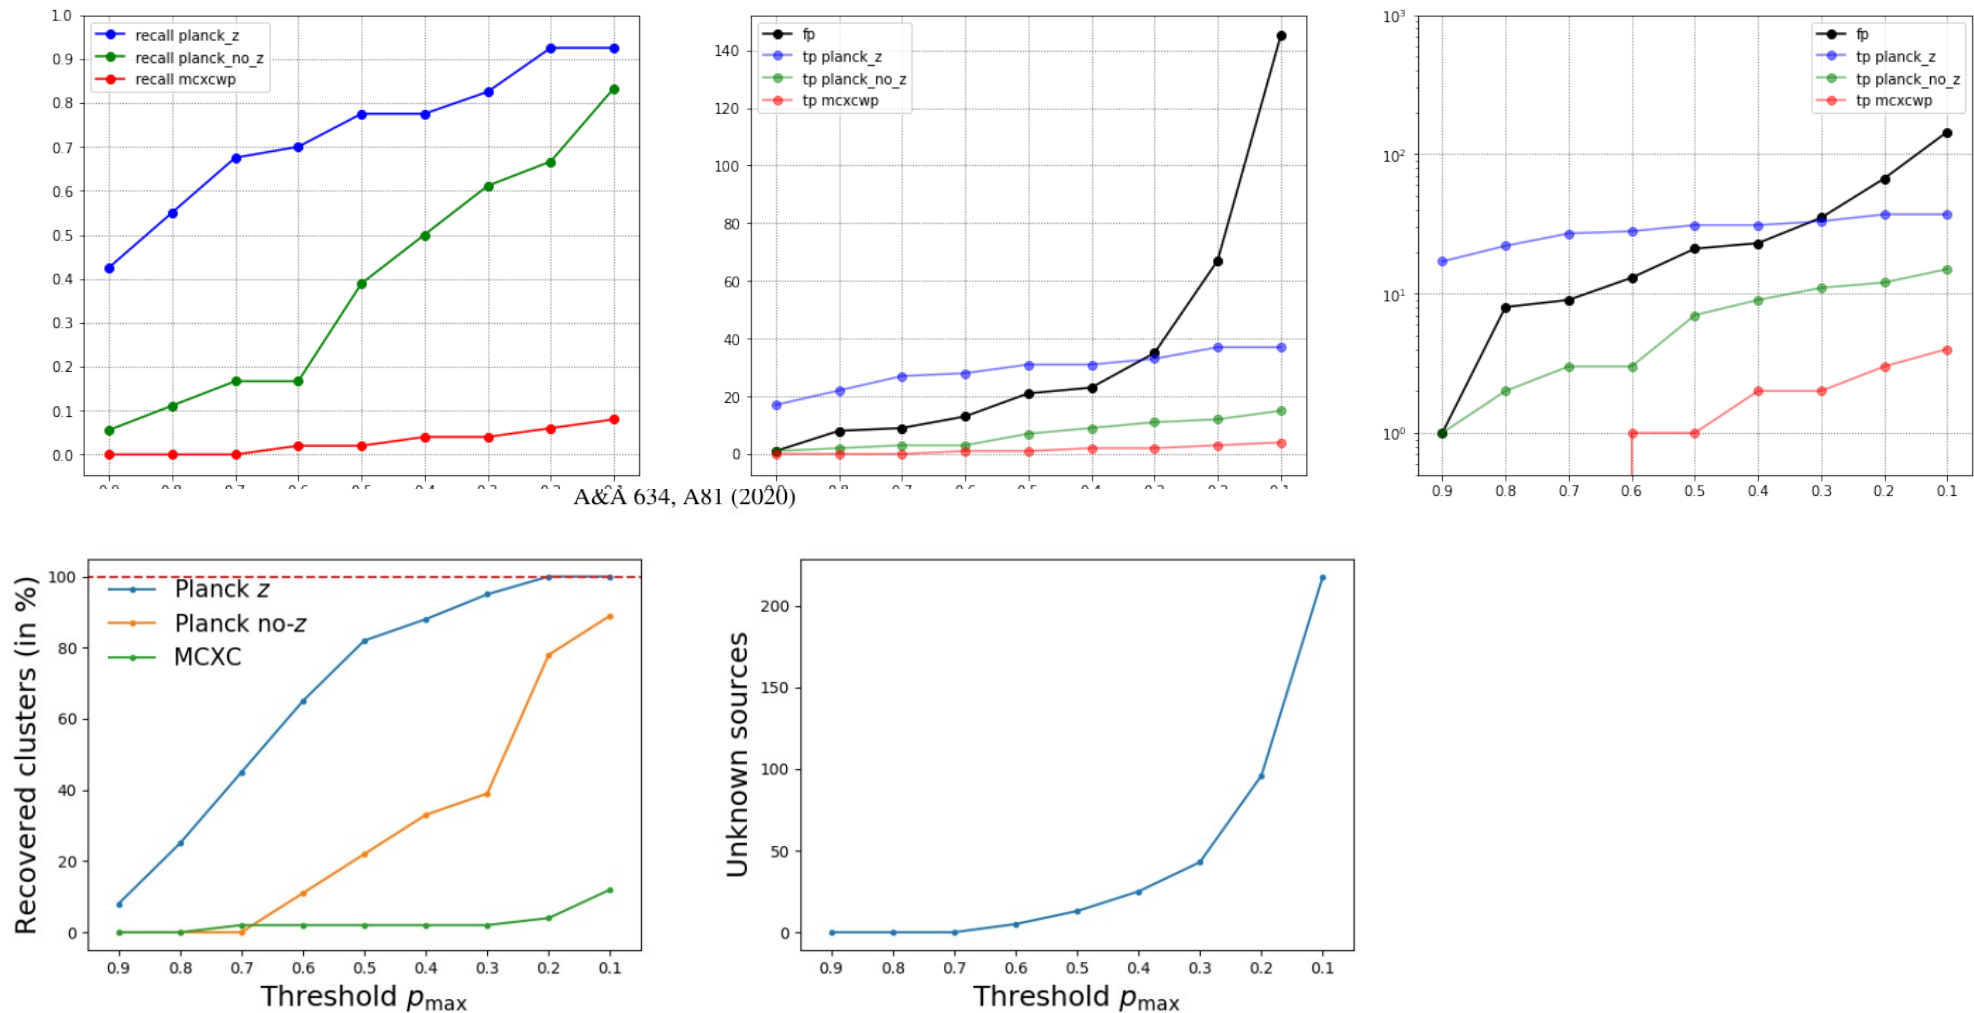


Fig. 3. Results on the test area containing 40 Planck_z, 18 Planck_no-z, and 50 MCXCwP galaxy clusters. *Left:* Galaxy clusters recovered with different detection thresholds p_{\max} . *Right:* number of sources recovered with the U-net that do not belong to the Planck or the MCXC catalogue as a function of the threshold p_{\max} .

	planck_z	planck_no_z	mcxcwp	fp	all	step	thr
0.1	0.875	0.666667	0.04	134	242	64	0.1
0.1	0.925	0.722222	0.08	136	244	32	0.1
0.1	0.925	0.833333	0.08	145	253	16	0.1
0.1	0.950	0.777778	0.10	119	227	8	0.1

	planck_z	planck_no_z	mcxcwp	fp	all	step	thr
0.2	0.825	0.666667	0.04	84	192	64	0.2
0.2	0.900	0.611111	0.06	74	182	32	0.2
0.2	0.925	0.666667	0.06	67	175	16	0.2
0.2	0.925	0.777778	0.08	60	168	8	0.2

Текущие результаты

- Обучена модель на данных Planck и каталоге `planck_z`
- Составлен каталог обнаруженных объектов для `step=8`, `thr=[0.1, 0.2]`.

Дальнейшие планы

- Проверить, насколько влияют на детекцию меньшие значения шага.
- Обучить модель на каталоге АСТ.
- Перейти на детекцию в других диапазонах излучения.